MovieLens movie ranking networks

Lars Müller

20. März 2026

Inhaltsverzeichnis

1 Einleitung 2

2 Forschungsfrage 3

3 Datenüberblick 4
- 3.1 Datensatz 4
- 3.2 Mögliche Abweichungen 4

4 Methodenüberblick 5

5 Projektbezogene Arbeiten 6

6 Experimentsaufbau 7

7 Ergebnisse und Diskussion 8
- 7.1 Gesamtbetrachtung 9
- 7.2 Zeitunterteilte Betrachtung 11

8 Fazit 13

1 Einleitung

Die Digital Humanities haben sich in den letzten Jahren zu einem etablierten, aber schwer erfassbaren Feld entwickelt. Während früher primär digitale Archive und quantitative Analysen charakteristisch für den Bereich waren, umfasst er heutzutage ein weitaus breiteres Spektrum, das von 3D-Modelling bis hin zu Hashtag-Aktivismus reicht. (Klein & Gold, 2016)

Dieser Wandel wird von Klein und Gold (2016) als „Big Tent“ (Großes Zelt) beschrieben, wodurch es mitunter schwierig ist, eine spezifische und präzise Definition für Digital Humanities zu finden.

Bla Bla das kommt noch. UND AUF JEDEN FALL NOCH DIE UNVERLÄSSIGE QUELLE BEI DER FORSCHUNGSFRAGE ENTFERNEN MORGEN LARS

2 Forschungsfrage

Die moderne Film- und Medienbranche ist national und international mit einem geschätzten Gesamtmarktwert im Jahr 2024 von 108,84 Milliarden USD eine der wichtigsten und erfolgreichsten Industrien der heutigen Zeit. (Zion Market Research, 2024) Mit einer jährlichen Wachstumsrate von über 7 % ist es essenziell, das Sehverhalten der Kunden bei einem stetig wachsenden Wettbewerb zu analysieren.

Das Ziel dieses Projektes ist es, Nutzer, basierend auf ihrem Filmgeschmack, in gleichartige Gruppen zu unterteilen und diese anschließend nach ausschlaggebenden Faktoren für diese Einordnung zu untersuchen. Zu Beginn werden Zuschauer mit gemeinsam gesehenen Filmen und angleichenden Wertungen in Gruppen unterteilt. Diese Ergebnisse werden folgend mit den Genrevorlieben der Nutzer verglichen, um eine mögliche Korrelation zwischen Filmgeschmack und Genre hervorzuheben. Dabei steht die Frage im Vordergrund, ob rein datengestützte Cluster durch klassische Kategorisierungen wie „Drama“, „Action“ oder „Horror“ repräsentiert werden können. Es soll geprüft werden, ob bestimmte Nutzergruppen eine signifikante Neigung zu gewissen Genrekombinationen aufweisen, welche als Fundament dieser Gruppen fungieren.

Weiterhin wird untersucht, inwieweit die zeitliche Dynamik das Sehverhalten beeinflusst. Dabei ist es interessant zu beobachten, ob sich der generelle Filmgeschmack über die Jahre gewandelt hat und welche strukturellen Auswirkungen dies auf die Formation der Cluster innerhalb des Netzwerks hat. Daraus lässt sich ableiten, ob die zunehmende Marktsättigung im Streamingsektor zu einer Homogenisierung des generellen Filmgeschmacks geführt hat, oder ob spezifische Cluster sich diesen Trend widersetzen.

Abschließend wird analysiert, welche Arten von Filmen – Nischenfilme oder Blockbuster – für die Bildung solcher Gruppen von hoher Relevanz sind. In diesem Kontext wird untersucht, ob populäre Blockbuster aufgrund ihrer hohen Reichweite als „Rauschen“ im Netzwerk fungieren, während spezielle Nischenfilme möglicherweise als stabilisierender Faktor dienen.

Der grundlegende Datensatz zur Auswertung der Forschungsfrage basiert auf einem Datenset von GroupLens. Darin enthalten sind 10 Millionen Zuschauerbewertungen von 72 000 Nutzern auf 10 000 Filme, wodurch dieser Datensatz eine ausreichend hohe Dichte aufweist, um signifikante Muster erkennen zu können.

Zur Auswertung der Daten wird eine Netzwerkanalyse zwischen den Zuschauern basierend auf unterschiedlichen Featureschwerpunkten durchgeführt. Nach einer hinreichend befriedigenden Clusteranalyse folgt ein Vergleich der einzelnen Ergebnisse mit dem Ziel, Auskunft über den digitalen Filmgeschmack zu erhalten und festzustellen, welche Faktoren von Relevanz sind, um das Sehverhalten abzubilden.

3 Datenüberblick

3.1 Datensatz

Der in dieser Projektarbeit verwendete Datensatz „MovieLens 10M“ wurde im Jahr 2009 von der Forschungsgruppe GroupLens veröffentlicht. (Harper & Konstan, 2015) Der Datensatz umfasst 3 Dateien, welche rund 10 Millionen Nutzerwertungen von rund 72 000 Zuschauern zu etwa 10 000 Filmen beinhalten. Jede Bewertung ist dabei mit einem Zeitstempel versehen. Die Auswahl der Zuschauer erfolgte mittels Zufallsprinzip, wobei als Einschlusskriterium eine Mindestanzahl von 20 Bewertungen pro Nutzer festgelegt wurde. Zusätzlich lässt sich jeder Film einem Genre zuordnen.

3.2 Mögliche Abweichungen

Eine mögliche Verzerrung der Netzwerkanalyse kann durch verschiedene Faktoren beeinflusst werden. Zunächst ist eine Einschränkung des Datensets auf das Einschlusskriterium von mindestens 20 Bewertungen pro Nutzer zurückzuführen. Zuschauer mit einem sehr spezifischen oder geringen Sehverhalten von wenigen Filmen werden dadurch nicht berücksichtigt. Dies führt dazu, dass die Bildung von potenziell kleinen Nischengruppen unterdrückt wird, wodurch das Netzwerk dichter erscheinen wird, als es in der Realität der Fall ist.

Weiterhin gibt es eine Verzerrung durch die sprachliche Barriere. Da die Reviewplattform, auf welcher der vorliegende Datensatz basiert, ausschließlich in englischer Sprache betrieben wird, sind nicht englischsprachige Kulturräume im Datensatz unterrepräsentiert. Dieser Zustand zeigt sich in der Zusammensetzung der Zuschauer, wie auch in der Auswahl der bewerteten Filme wieder. Insbesondere internationale Filme weisen somit eine geringe Repräsentanz auf.

Über die sprachliche Barriere hinaus werden Zuschauer systematisch ausgeschlossen, welche ein hohes Konsumverhalten aufweisen, dieses aber nicht auf einer Onlineplattform dokumentieren. Speziell die ältere Generation der Zuschauer, welche häufig eine Technikaffinität aufweist und mit den modernen Mechaniken heutiger digitaler Bewertungsplattformen nicht vertraut ist, wird dadurch stark ausgegrenzt. Folglich bildet der Datensatz primär das Sehverhalten der jüngeren Generation ab, wodurch Filmklassiker im Vergleich zu neueren Produktionen potenziell vernachlässigt werden.

Eine weitere mögliche Verzerrung folgt aus extremistischen Bewertungen. Viele Menschen neigen dazu, Filme vor allem dann zu bewerten, wenn sie diese überragend gut oder enttäuschend schlecht finden. Filme mit einer statistisch durchschnittlichen Wertung könnten somit seltener dokumentiert werden.

Es ist deutlich, dass die oben geschilderten Faktoren den Bias unseres Datensatzes beeinflussen. Trotzdem ermöglicht eine Analyse dieses Datensatzes einen wertvollen Einblick in das dynamische Sehverhalten.

4 Methodenüberblick

Moderne Datensätze, wie der in diesem Projekt verwendete, beinhalten eine immense Anzahl an Datenpunkten und komplexen Interaktionen. Eine Analyse ohne digitale, moderne Analysemethoden ist somit nicht mehr praktikabel. Um die komplexen Abhängigkeiten zwischen Nutzern, Filmen und Genres explizit darzustellen und zu untersuchen, wird die Netzwerkanalyse als zentrale Methode in diesem Projekt angewendet, welche einen speziellen Schwerpunkt auf Akteure und deren Beziehungen legt. (Serrat, 2017)

Die grundlegende Idee der Netzwerkanalyse besteht darin, Beziehungen zwischen den Daten zu finden. Dargestellt wird dies mithilfe eines Netzwerkes, bestehend aus Knoten, welche mit gerichteten oder ungerichteten Kanten verbunden sind. Sowohl Knoten, auch Entitäten genannt, als auch Kanten können entsprechende Labels für eine bessere Visualisierung erhalten. Weiterhin können Kanten je nach Wichtigkeit ein entsprechendes Gewicht besitzen. Je nach Szenario wird somit zwischen gerichteten, ungerichteten und gewichteten Relationen unterschieden.

Den Daten entsprechend kann neben ausschließlich gleichartigen Knoten in einem 1-mode-Netzwerk auch ein bipartites Netzwerk mit Knoten zweier Typen aufgestellt werden.

Die Analyse des Netzwerks umfasst verschiedene Vorgehensweisen. Visuell repräsentiert können alleinstehende Gruppenstrukturen direkt erkannt werden. In dem auf unserem Datensatz basierenden Netzwerk sind dies Zuschauer mit einem ähnlichen Sehverhalten, welche allerdings zu keinen anderen Zuschauern außerhalb der Gruppe eine ähnlich hohe Gemeinsamkeit aufweisen. Um Gruppenstrukturen ausfindig zu machen, welche nicht auf kompletter Isolation aufbauen, ist die Modularität als Maßstab für die relative Dichte von Unterstrukturen essenziell.

Trotz der Vorteile der Netzwerkanalyse müssen methodische und datensettechnische Limitationen berücksichtigt werden. Aus der erwähnten Größe des Datensatzes folgt eine zwingend erforderliche Filterung von relevanten Datensätzen, damit eine digitale Analyse im Hinblick auf die Zeitkomplexität, auf Kosten der Datenvielfalt, möglich ist.

Neben den in 3.2 aufgelisteten Schwachpunkten des Datensatzes zeigt auch die Methode nicht vermeidbare Schwachstellen. Ein durch die Netzwerkanalyse indiziertes, ähnliches Sehverhalten bedeutet nicht gleich, dass ein echter gemeinsamer Geschmack vorliegt; Bewertungen sind subjektiv; dementsprechend können Zuschauer Filme aus völlig unterschiedlichen Gründen gleich bewerten, wodurch eine klare Geschmacksdifferenz vorliegt, welche in der Netzwerkanalyse nicht berücksichtigt wird.

Abschließend hängen die Beziehungsergebnisse außerdem stark von der verwendeten Vergleichsmetrik ab. Wichtig ist daher, eine entsprechende Balance zwischen gemeinsam gesehenen Filmen, der individuellen Bewertung und dem übergeordneten Genre zu finden.

5 Projektbezogene Arbeiten

In dem Paper „Incorporating social networks and user opinions for collaborative recommendation: local trust network based method“ wird durch Netzwerkanalyse erforscht, wie soziale Strukturen und Nutzervertrauen die Qualität von Filmempfehlungen verbessern können. Die Studie zeigt, dass die Modellierung von Vertrauensbeziehungen zwischen Nutzern – anstatt rein statistischer Ähnlichkeiten – die Vorhersagegenauigkeit signifikant steigert. (Liu et al., 2010)

Das Paper „An Improved Study of Multilevel Semantic Network Visualization for Analyzing Sentiment Word of Movie Review Data“ untersucht mittels Netzwerkanalyse, wie eine grafische Darstellung von Stimmungswörtern das intuitive Verständnis komplexer Review-Daten verbessert. Daraus konnten neue Methoden als Schlüsselfaktoren identifiziert werden, die es Nutzern ermöglichen, emotionale Muster und Zusammenhänge zwischen Filmen genauer zu erkennen. (Ha et al., 2019)

Ein weiteres Paper mit dem Titel „Rating Prediction in Recommender Systems Based on User Behavior Probability and Complex Network Modeling“ hat die Netzwerkanalyse verwendet, um ein neuartiges Ähnlichkeitsmaß zwischen Nutzern einer Reviewplattform zu entwickeln, das über den Vergleich historischer Bewertungen hinausgeht. Durch Anwendung der Netzwerkmodellierung wurden Empfehlungsalgorithmen entwickelt, die auf einer komplexen Metrik basieren. Diese Metrik integriert sowohl individuelle Verhaltenswahrscheinlichkeiten als auch topologische Netzwerkparameter wie den Nutzergrad und Community-Strukturen, um die Empfehlungsqualität signifikant zu steigern. (Su et al., 2021)

6 Experimentsaufbau

Die Methode der Netzwerkanalyse wird auf verschiedene Teildatensätze, basierend auf den uns wichtigen Eigenschaften, angewendet.

Damit eine sinnvolle Netzwerkanalyse ausgeführt werden kann, ist es essenziell, den vorhandenen Datensatz in R zu überarbeiten und zu filtern. Aufgrund der immensen Datenmenge wird die Analyse auf 1 000 Zuschauer begrenzt, damit ein komplexer Vergleich zeittechnisch möglich ist. Um das breite Spektrum möglichst präzise repräsentieren zu können, werden die Nutzer mittels Zufallsprinzip bei einem gleichbleibenden Zufalls-Seed ausgelost, damit eine Konstanz für spätere Analysen gewährleistet wird.

Anschließend wird eine Nutzer-Nutzer-Matrix erstellt, welche die ausschlaggebende Sehverhaltensmetrik für jedes Nutzerpaar beinhaltet und zeitgleich als Adjazenzmatrix für eine spätere Visualisierung dient. Die Sehverhaltensmetrik wird aus zwei wichtigen Features berechnet. Einerseits sollte bei einem sich ähnelnden Filmgeschmack eine angleichende gesehene Filmhistorie vorliegen, sprich: Die Menge der gemeinsam gesehenen Filme sollte möglichst nah an die von beiden insgesamt gesehene Anzahl an Filmen heranreichen. Andererseits ist die Bewertung der gemeinsam gesehenen Filme beider Nutzer von ausschlaggebender Bedeutung. Falls ein gemeinsamer Filmgeschmack vorliegt, dann sollte sich dieser in einer ähnlichen Wertung der Filme widerspiegeln. Um eine möglichst vielseitige Analyse zu gewährleisten, ist es möglich, die Gewichtung der beiden Metrik-Features mit einem Parameter zu kontrollieren.

Damit eine sinnvolle Netzwerkanalyse möglich ist, werden all diejenigen Kanten entfernt, welche einen gewissen Schwellenwert unterschreiten, damit nicht jede noch so kleine Ähnlichkeit zu einer visuellen Kante führt. Folgend wird mittels Adjazenzmatrix ein ungerichteter Netzwerkgraph konstruiert, welcher die Nutzer als Knoten und die entsprechende Ähnlichkeitsmetrik zu anderen Nutzern als Kanten darstellt. Vorliegende Communitys werden anschließend mithilfe des „cluster louvain“-Algorithmus – basierend auf einer möglichst hohen lokalen modularität – ausfindig gemacht.

Um eine potenzielle Korrelation zwischen Gruppen und Genres herausstellen zu können, wird eine Genreanalyse für jedes vorliegende Cluster durchgeführt. Die drei Hauptgenres jeder Gruppe werden daraufhin in tabellarischer Form als prozentuale Verteilung bereitgestellt.

Damit eine Analyse der Filme, die als Hauptfaktor für eine solche Clusterbildung infrage kommen, durchgeführt werden kann, wird analog zur Genreanalyse eine Tabelle hinzugefügt, welche den Anteil der pro Gruppe gesehenen Filmearten prozentual vergleicht. Hierbei werden Filme mit einer geringen Anzahl an Rezensionen als Nischenfilme bezeichnet – und vice versa solche mit den häufigsten Bewertungen als Blockbuster.

7 Ergebnisse und Diskussion

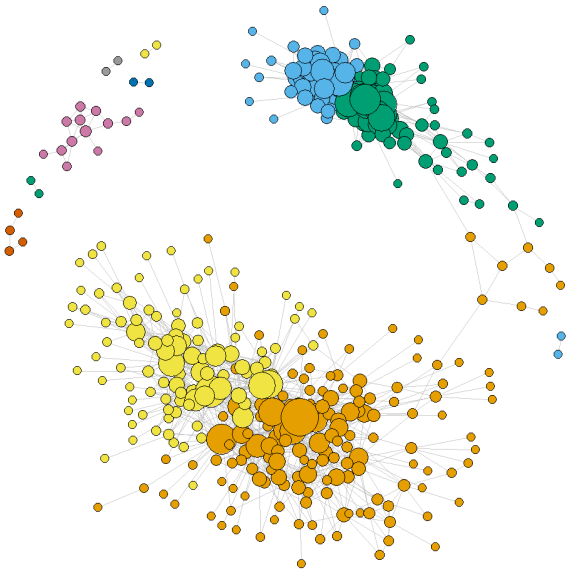

(a) Netzwerk-Graph

community	1	2	3
1	Drama (18.1%)	Comedy (16.4%)	Action (10%)
2	Drama (14.4%)	Action (12.8%)	Comedy (12.3%)
3	Drama (19.2%)	Comedy (15.7%)	Action (10.3%)
4	Drama (15.1%)	Comedy (14%)	Action (12.4%)
5	Drama (18.1%)	Comedy (17.6%)	Thriller (11.4%)
6	Action (17.8%)	Sci-Fi (12.3%)	Adventure (11.6%)
7	Drama (15.7%)	Thriller (14.3%)	Comedy (13.8%)
8	Romance (35%)	Drama (20.9%)	Comedy (20.6%)
9	Drama (22%)	Comedy (15.3%)	Romance (9.3%)
10	Drama (18.6%)	Thriller (14.2%)	Action (13.2%)
11	Comedy (17.9%)	Drama (12.4%)	Action (10.7%)
12	Drama (21.1%)	Comedy (18.2%)	Romance (13%)

(b) Genre-Tabelle

community	Popular	Average	Niche
1	67.47	31.12	1.42
2	98.64	1.36	0
3	86.08	13.16	0.76
4	89.1	10.75	0.15
5	97.02	2.98	0
6	95.65	4.35	0
7	97.2	2.8	0
8	84.65	15.35	0
9	87.37	12.63	0
10	89.88	10.03	0.09
11	87.79	12.21	0
12	75.79	24.01	0.21

(c) Filmart Tabelle in %

Abbildung 1: Analyse des gesamten Zeitraums

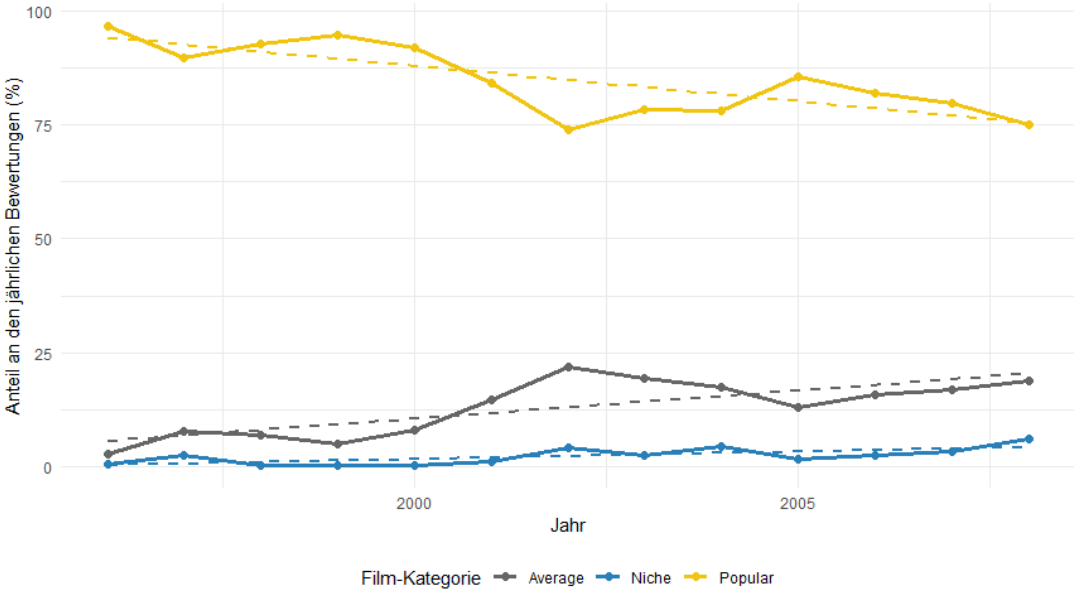

Abbildung 2: Sehverhalten im Zeitverlauf

Im Folgenden werden die ausgearbeiteten Ergebnisse präsentiert, welche als Grundlage für die Diskussion basierend auf den Forschungsfragen dienen. Damit eine präzise Auswertung erfolgen kann, wird der zeittechnische Aspekt gesondert in Abschnitt 7.2 behandelt.

7.1 Gesamtbetrachtung

Die Analyse des gesamten Zeitraums liefert eine klare Struktur des Nutzer-Netzwerks und erlaubt erste Rückschlüsse auf zugrunde liegende Präferenzmuster. Der in Abbildung 1a illustrierte Netzwerkgraph visualisiert die Cluster-Verteilung von 1 000 zufällig ausgewählten Personen. Die zugehörigen Tabellen (Abbildung 1b und 1c) geben Auskunft über die Genreverteilung und die dominierende Filmart innerhalb der jeweiligen Segmente.

Visuell lässt sich eine deutliche Abgrenzung einzelner Nutzergruppen identifizieren. Mit einer Modularität von rund 0,61, weist das Netzwerk auch faktentechnisch eine signifikante Community-Struktur auf. Die Existenz solcher Cluster liefert eine erste positive Antwort auf die Frage, ob sich Communitys, bestehend aus Nutzern mit ähnlichem Geschmack, aus den Daten ableiten lassen.

Abbildung 1b zeigt, dass diese Gruppen nicht zufällig entstehen, sondern in manchen Fällen eine direkte Korrelation zu spezifischen Genres aufweisen. So lassen sich beispielsweise Cluster beobachten, welche eine überdurchschnittliche Präferenz für gewisse Genres zeigen. Stark herausstechend ist die Community 8, welche immens durch das Genre Romantik, mit einem prozentualen Anteil von 35 %, gefolgt von Drama mit gerade einmal 20,9 %, definiert ist. Weitere Gruppen wie 6, 9 oder 11 weisen klare Tendenzen hin zu spezifischen Genres auf, während insbesondere größere Gruppen eine sich angleichende Genreverteilung, geprägt von Drama, Comedy und Action, vorweisen. Schlussfolgernd daraus lässt sich keine klare Genrekorrelation für jede Gruppe zuordnen, da der Filmgeschmack multidimensional ist und sich nicht auf einzelne Kategorien reduzieren lässt. Dennoch zeigt sich, dass bestimmte Genres als grundlegender Kern einzelner Communitys fungieren, womit die Frage nach der Genrezugehörigkeit für bestimmte Gruppen bestätigt ist.

Die Analyse der Filmarten innerhalb der Cluster (Abbildung 1c) liefert konkrete Erkenntnisse, welche Rolle populäre und wenig populäre Filme für die Unterteilung spielen. Es zeigt sich, dass Blockbuster, die in dem verwendeten Datenset durch die Top 20 % der Filme repräsentiert werden, für viele Gruppen eine klare Filmtendenz darstellen. Vor allem die Cluster 2, 5 und 7 setzen sich aus Personen zusammen, welche fast ausschließlich an der Filmart des Blockbusters interessiert sind, während spezifisch Gruppe 2 den Höchstwert von 98.64 % aufstellt.

Im Gegensatz dazu, lässt sich aus den bereitgestellten Abbildungen keine klare Signifikanz von Nischenfilmen feststellen. Ein möglicher Faktor dafür ist auf die Nutzerauswahl des Datensatzes zurückzuführen, welcher Personen erst dann eingeschlossen hat, wenn diese eine Rezensionszahl von mindestens 20 Bewertungen erreicht haben. Außerdem zeigt Abbildung 2 eine erkennbare Tendenz hin zu weniger bekannten Filmen, was darauf hindeutet, dass eine Analyse aktueller Daten mögliche Veränderungen im Nutzerverhalten aufzeigen kann. Des Weiteren führt die randomisierte Stichprobenziehung dazu, dass spezifische Nischengruppen unterrepräsentiert sein können. Diese setzen sich primär aus Nutzern

zusammen, die aufgrund einer geringen Anzahl an Rezensionen im unteren Aktivitätsspektrum auffindbar sind. Ein letzter Grund für dieses Ergebnis liegt in der angewandten Methodik zur Identifikation von Nischenfilmen aus dem Datensatz. Obwohl die Filterung nach Filmen aus dem unteren Spektrum der Reviewzahlen durchaus als valide Einschränkung für den Nischenstatus dient, treten vereinzelt Diskrepanzen auf. So existieren Produktionen, die zwar in diese Unterteilung hineingehören, aufgrund einer überdurchschnittlichen globalen Aufmerksamkeit jedoch exkludiert wurden. Umgekehrt existieren aktuelle Blockbuster, die durch ihre zeitnahe Markteinführung ein noch geringes Reviewvolumen aufweisen und somit trotz Blockbusterstatus in die Kategorie der Nischenfilme fallen.

Dennoch weist Gruppe 1 eine bemerkenswerte Tendenz weg von populären Produktionen auf. Mit einem Anteil von 67.47 % stellt diese Community einen deutlichen Ausreißer im Vergleich zu den anderen Clustern dar.

Zusammenfassend lässt sich festhalten, dass Blockbuster aufgrund ihrer hohen Popularität zwar als Rauschen im Netzwerk interpretiert werden können, jedoch für bestimmte Gruppen als fundamentales Identifikationsmerkmal dienen. Auch wenn Gruppe 1 eine Tendenz hin zu weniger populären Filmen aufweist, lässt sich auf Basis der gefilterten Daten keine eindeutige Aussage über Nischenfilme treffen.

7.2 Zeitunterteilte Betrachtung

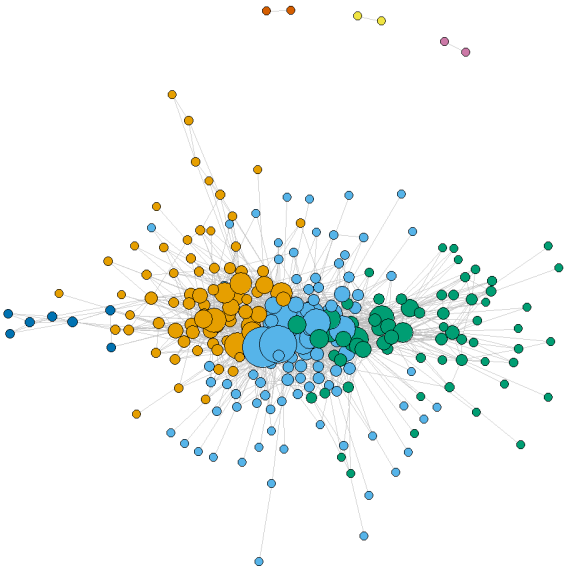

(a) Netzwerk-Graph

community	1	2	3
1	Drama (15.7%)	Comedy (15.6%)	Action (11.8%)
2	Drama (14.8%)	Comedy (14.4%)	Action (12.4%)
3	Drama (14.6%)	Comedy (13.8%)	Action (12.9%)
4	Drama (24.5%)	Comedy (17.9%)	Romance (14.1%)
5	Drama (20.2%)	Comedy (16.4%)	Thriller (10.2%)
6	Drama (20.5%)	Comedy (17.4%)	Action (9.9%)
7	Drama (26.6%)	Thriller (11.4%)	Crime (8.6%)

(b) Genre-Verteilung

community	Popular	Average	Niche
1	73.55	25.73	0.72
2	85.33	14.42	0.25
3	94.55	5.21	0.24
4	65.06	34.33	0.61
5	43.65	51.24	5.12
6	61.29	38.32	0.38
7	60.69	38.06	1.26

(c) Filmart in %

Abbildung 3: Analyse des Zeitraums 2005–2009

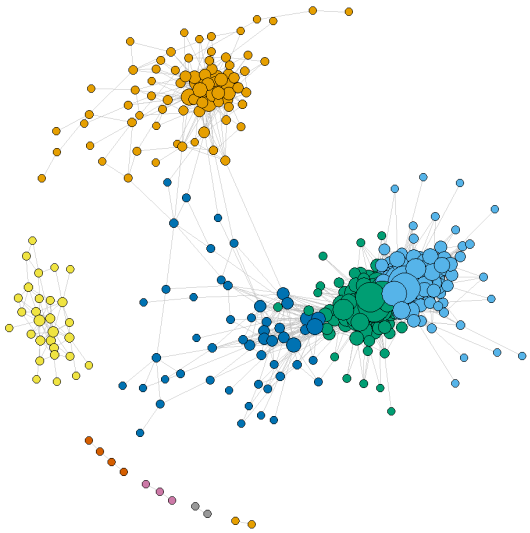

(a) Netzwerk-Graph

community	1	2	3
1	Drama (19%)	Comedy (17.2%)	Action (9.4%)
2	Drama (15%)	Comedy (13.1%)	Action (12.7%)
3	Drama (18.1%)	Comedy (16%)	Action (11%)
4	Comedy (16%)	Drama (14.7%)	Thriller (13.9%)
5	Drama (18.4%)	Comedy (15%)	Action (10.1%)
6	Action (17.8%)	Sci-Fi (12.3%)	Adventure (11.6%)
7	Comedy (16.5%)	Action (12.4%)	Drama (11.3%)
8	Action (23.6%)	Sci-Fi (16.2%)	Adventure (14.3%)
9	Romance (35%)	Drama (20.9%)	Comedy (20.6%)

(b) Genre-Verteilung

community	Popular	Average	Niche
1	70.73	28.72	0.55
2	98.63	1.37	0
3	91.95	7.9	0.15
4	95.73	4.27	0
5	87.15	12.33	0.53
6	95.65	4.35	0
7	93.86	6.14	0
8	95.11	4.89	0
9	84.65	15.35	0

(c) Filmart in %

Abbildung 4: Analyse des Zeitraums 1995–2000

Die zeitliche Unterteilung ermöglicht einen Blick auf die Dynamik der Nutzerpräferenzen und die daraus resultierenden Netzwerkstrukturen. Im Folgenden werden die in Abbildung 3 (2005–2009) und Abbildung 4 (1995–2000) dargestellten Ergebnisse miteinander verglichen, um mögliche Veränderungen im Sehverhalten und in der Clusterbildung zu identifizieren. Es ist zu erwähnen, dass beide Abbildungen um jeweils 1 000 Nutzer erweitert wurden, damit die in einigen Zeitperioden geringe Datendichte ausgeglichen werden kann und eine konsistente Visualisierung gewährleistet wird.

Ein direkter visueller Vergleich der Netzwerkgraphen zeigt, dass in beiden Zeiträumen grundlegende Clusterstrukturen vorhanden sind, die sich allerdings in ihrer Ausdehnung unterscheiden. Während der frühere Zeitraum eine stärkere Fragmentierung mit klar voneinander getrennten Gruppen aufweist, erscheint der Graph im späteren Zeitraum mit vielen Vernetzungen erkennbar dichter. Mit einer Modularität von rund 0,42 weist der Graph, basierend auf den älteren Datensätzen, eine klare Community-Struktur auf, während das Vergleichsnetzwerk mit einer Modularität von 0,34 Cluster beinhaltet, welche spürbar weniger untereinander abgegrenzt sind. Eine mögliche Erklärung für das zunehmend konvergierende Sehverhalten ist der Einfluss sozialer Medien auf die Filmauswahl. Wie Wang et al. (2015) zeigen, fungieren Plattformen wie Twitter als zentrale Katalysatoren für das Zuschauerinteresse. Der daraus folgende globale Informationsaustausch kann dazu führen, dass sich Präferenzmuster angleichen, wodurch die Grenzen zwischen ehemals isolierten Nutzergruppen verschwimmen.

Eine Analyse der Genreverteilung stützt diese Beobachtung. In Abbildung 4b zeigen einzelne Cluster tendenziell spezifischere und voneinander abgrenzende Genrepräferenzen. Im Gegensatz dazu ist den Gruppen der Abbildung 3b eine breite Überschneidung in ihren Genreprofilen, bestehend aus fast ausschließlich Drama, Comedy und Action, nachzuweisen. Dies spricht dafür, dass Nutzer sich im Zeitverlauf weniger strikt auf bestimmte Genres festlegen und stattdessen ein breites Spektrum an Inhalten konsumieren. Eine wesentliche Erklärung hierfür liegt im stetigen Wachstum des globalen Video-Streaming-Marktes. Mit einer prognostizierten jährlichen Wachstumsrate von rund 17 % führt diese Marktexpansion zu einem stetig wachsenden Angebot an direkt abrufbaren Filmen. (Fortune Business Insights, 2026)

Auch die Betrachtung der Filmart zeigt deutliche Unterschiede. Während im früheren Graphen Nischenfilme über alle Cluster hinweg stark vernachlässigt wurden und populäre Filme dominierten, zeigt der Vergleichsgraph eine Tendenz hin zu weniger bekannten Filmen. Speziell Gruppe 5 weist mit einem Nischenanteil von über 5 % sogar ein erhebliches Alleinstellungsmerkmal auf. Die Ursache dafür könnte wieder auf die sozialen Netzwerke zurückgeführt werden, welche auch Nischenfilmen eine Plattform bieten und als kostengünstiges Werbemittel fungieren können.

Insgesamt lässt sich feststellen, dass sich die Struktur des Netzwerkes im Zeitverlauf nicht nur in der Dichte, sondern auch in den zugrunde liegenden Inhalten stark verändert hat.

Alle verwendeten Grafiken sowie der dazugehörende Programmcode sind unter folgendem Link einsehbar: https://github.com/NextLvlZerO/MovieRankingNetwork

8 Fazit

Die zentrale Motivation dieses Projekts hat sich mit der Analyse – durch Methoden der Digital Humanities – des filmischen Sehverhaltens von Personen beschäftigt. Die Methodik sollte primär Auskunft über eine mögliche Clusterbildung zwischen den Nutzern geben und weiterführend einzelne Faktoren hinsichtlich ihrer Auswirkung auf die Gruppenbildung und möglicher Parallelen untersuchen.

Die Netzwerkanalyse hat gezeigt, dass es eine klar definierte Gruppenunterteilung zwischen den Zuschauern gibt. Durch die Abbildung 1b wurde deutlich gemacht, dass vereinzelt Gruppen existieren, welche in direkter Korrelation zu einem oder mehreren Genres stehen. Dies ist allerdings nicht die Norm. Weiterhin hat die genaue Betrachtung der für jede Gruppe dominierenden Filmart eine klare Tendenz zu den Blockbusterfilmen deutlich gemacht, während keine Gruppen stellvertretend für Nischenfilme gefunden werden konnten. Es wurde folgend in 7.2 gezeigt, wie die Zeit als Maß Auswirkungen auf die Clusterbildung hat. Während in Abbildung 4a noch klar voneinander visuell trennbare Cluster zu erkennen waren, stellt der moderne Graph (Abbildung 3a) eine klare Verschwimmung der Communitys dar.

Die Methodik der Netzwerkanalyse ist für die technische Auswertung der Daten mit Blick auf die gestellte Forschungsfrage perfekt geeignet gewesen. Der Informationsverlust bezüglich der Gemeinsamkeitsmetrik zweier Personen erschwert es jedoch, direkte Filmempfehlungen zu geben. Auch wenn zwei Nutzer ein in dem Graphen stark ähnliches Sehverhalten aufzeigen, ist nicht direkt ersichtlich, welche Faktoren dafür von signifikanter Relevanz waren.

Für zukünftige Arbeiten, die auf einer ähnlichen Forschungsfrage basieren, sollte ein größeres Datenvolumen analysiert werden, um vielleicht existierende Nischengruppen, welche in diesem Projekt nicht gefunden wurden, zu erkennen. Weiterhin sind die unterschiedlichen Reviewzeiten jedes Nutzers problematisch. Die wenigsten Nutzer sind über den Gesamtzeitraum von 1995 bis 2009 aktiv auf der untersuchten Plattform gewesen, wodurch Inkonsistenzen in ihrem Sehverhalten entstehen können. Abschließend könnte neben der puren Bewertung auch die geschriebene Rezension selbst als weiterer Faktor dienen, um das Sehverhalten noch genauer beschreiben zu können.

Literaturverzeichnis

Fortune Business Insights. (2026). *Video-Streaming-Marktgröße, Anteil und Branchenanalyse*. Verfügbar 19. März 2026 unter https://www.fortunebusinessinsights.com/de/video-streaming-markt-103057

Ha, H., Han, H., Mun, S., Bae, S., Lee, J., & Lee, K. (2019). An Improved Study of Multilevel Semantic Network Visualization for Analyzing Sentiment Word of Movie Review Data. *Applied Sciences*, *9*, 2419. https://www.mdpi.com/2076-3417/9/12/2419

Harper, F. M., & Konstan, J. A. (2015). *The MovieLens Datasets: History and Context*. Verfügbar 9. März 2026 unter https://files.grouplens.org/datasets/movielens/ml-10m-README.html

Klein, L. F., & Gold, M. K. (2016). *Digital Humanities: The Expanded Field*. University of Minnesota Press. Verfügbar 19. März 2026 unter https://muse.jhu.edu/pub/23/oa_edited_volume/chapter/1815141#page=307

Liu, F., Wang, B., Yan, J., & He, S. (2010). Incorporating social networks and user opinions for collaborative recommendation: local trust network based method, 53–56. https://dl.acm.org/doi/abs/10.1145/1869652.1869661

Serrat, O. (2017). *Knowledge Solutions* (1. Aufl.). Springer Singapore.

Su, Z., Lin, Z., Ai, J., & Li, H. (2021). Rating Prediction in Recommender Systems Based on User Behavior Probability and Complex Network Modeling. *IEEE Access*, *9*, 30739–30749. Verfügbar 18. März 2026 unter https://ieeexplore.ieee.org/abstract/document/9357332

Wang, X., Gaikar, D. D., Marakarkandy, B., & Dasgupta, C. (2015). Using Twitter data to predict the performance of Bollywood movies. *Industrial Management & Data Systems*, *115*(9), 1604–1621.

Zion Market Research. (2024). *Perspektive der Film- und Unterhaltungsbranche*. Verfügbar 17. März 2026 unter https://www.zionmarketresearch.com/de/report/global-movies-entertainment-market